

# Prueba técnica | AI Product Engineer

Forecasting, sensibilidad al precio y promociones

## Enfoque

Trabajé con 283,533 transacciones de seis SKUs. Antes de modelar revisé nulos, cancelaciones, ventas de muestra y la relación entre precio, costo y margen. El punto más importante fue confirmar que `product_margin` es un markup sobre costo. Por eso, un markup de 20% no permite descontar 20%: el margen real sobre ingreso es 16.7%.

Excluí 500 tickets con cantidad cero de los análisis de demanda. Las 500 ventas con monto cero sí cuentan en unidades, pero no en los modelos de precio. Para descuentos nulos usé cero en ventas orgánicas y la mediana del combo en ventas promocionales. Los costos y montos brutos faltantes se reconstruyeron con la relación observada de cada SKU. Además, calculé el costo dentro de cada periodo promocional, porque usar un costo histórico fijo alteraba algunos resultados de margen hasta 44%.

El brief presenta dos cifras distintas para clientes y periodo. En el archivo encontré 41,334 clientes y fechas del 6 de enero de 2025 al 3 de enero de 2027; trabajé con esos valores.

## Reto A | Pronóstico de demanda

Proyecté diez semanas para los tres SKUs con mayor volumen. Validé con cinco cortes walk-forward: en cada corte el modelo sólo ve información anterior a la semana que intenta predecir. Usé WAPE porque expresa el error como porcentaje del volumen total y no se dispara en semanas pequeñas.

| Modelo                 | Shampoo Rizos | Desodorante | Cubito | Uso                  |
|------------------------|---------------|-------------|--------|----------------------|
| Seasonal naive         | 16.2%         | 38.2%       | 10.0%  | Baseline anual       |
| LightGBM               | 13.9%         | 59.4%       | 10.4%  | Calendario y rezagos |
| LightGBM + promociones | 14.3%         | 9.2%        | 10.2%  | Modelo final         |

Elegí LightGBM con calendario promocional para los tres SKUs. Su WAPE promedio es 11.2%. La mejora principal aparece en Desodorante, donde las promociones duplican la demanda y el modelo sin calendario no puede anticiparlas. Considero válido usar ese calendario porque el equipo comercial lo define antes del horizonte de reabasto.

## Reto B | Sensibilidad al precio

Para el SKU con mayor variación ajusté una regresión log-log de demanda semanal contra precio efectivo, con tendencia y estacionalidad. La elasticidad estimada está entre -2.98 y -2.58, según se controle o no por semanas con combo.

Tomo ese rango con cautela. El precio cambia casi siempre cuando hay una promoción; la correlación entre precio y combo activo es -0.93. El coeficiente mezcla precio, visibilidad y mecánica promocional, así que no lo interpreto como un efecto causal puro. Dentro del rango observado, el simulador muestra que el precio que maximiza ingreso (\$46.36) queda por debajo del costo unitario (\$46.85). Mi recomendación es no perseguir ingreso a costa de margen. Con más datos probaría precios por bodega para separar mejor cada efecto.

## Reto C | Uplift promocional

Estimé el contrafactual de los 19 combos con un modelo estacional entrenado sólo en semanas sin promoción del mismo SKU. Después comparé las unidades observadas contra esa base. Para evaluar rentabilidad separé la ganancia de las unidades adicionales y el costo de aplicar el descuento a todas las unidades vendidas durante la promoción.

Hay dos cosas que suelen confundirse y conviene separar. En absoluto, 17 de las 19 promociones dejaron margen positivo: vendieron por encima del costo. Sólo dos vendieron a pérdida. Pero ninguna superó lo que habría dejado vender ese mismo volumen a precio de lista. La mejor, Combo Verano 2, recuperó 61 centavos por cada peso de margen sacrificado; la mediana del portafolio recupera 37.

La conclusión descansa entera en el contrafactual, así que la puse a prueba. El modelo tiene entre 6% y 10% de error sobre las semanas sin promoción y subestima la demanda entre 0.3% y 0.8%, o sea que si algo hace es favorecer a las promociones. Para que la mejor llegara al equilibrio, el contrafactual tendría que estar sobreestimado en 39%. Verifiqué además el margen por dos vías independientes y difieren menos de 1.5%. Con un grupo de bodegas sin promoción usaría eso como control en lugar del modelo.

## Recomendaciones

- Definir un tope de descuento por SKU y usarlo como regla de aprobación. En este portafolio los límites van de 18.0% a 23.1%.
- Suspende Combo Quincena Desodorante y Combo Cierre Trimestre Desodorante. Ambos cruzan el costo unitario.
- Volver a probar Combo Verano 2 con menor descuento y sólo en algunas bodegas. Es la que más se acercó: recuperó 61 centavos por cada peso de margen sacrificado, la mejor del portafolio.
- No aprobar promociones sólo porque el descuento parece bajo. Combo Temporada Fría descontó 10% y perdió \$61,816 por su baja respuesta de demanda.
- Usar el escenario promocional del forecast para reabasto y recalibrarlo cada cuatro a seis semanas.

## Trade-offs y qué haría distinto

- Ninguna promoción superó a su contrafactual, aunque 17 de 19 sí dejaron margen positivo. Antes de concluir que el trade marketing destruye valor, confirmaría con el cliente si el objetivo declarado es margen o si estas campañas compran distribución, espacio en anaquel o defensa competitiva. Son beneficios reales que este dataset no captura.
- El contrafactual del Reto C es estacional, no causal. Con más tiempo probaría control sintético o un diseño A/B geográfico entre bodegas con y sin promoción, que separaría el efecto promocional de la estacionalidad general.
- La elasticidad del Reto B no es identificable limpiamente porque el precio sólo se mueve cuando hay combo. Un test de precio aleatorizado por bodega, aunque fuera pequeño, valdría más que cualquier refinamiento del modelo actual.
- En el Reto A agregaría modelos jerárquicos que compartan información entre SKUs y bodegas, e intervalos de predicción: para reabasto importa tanto el nivel de servicio como el punto central.
- Con un alcance de cuatro a seis horas prioricé cubrir los tres retos con métodos explicables y validar los resultados por dos vías, en lugar de afinar hiperparámetros o probar arquitecturas más complejas como SARIMA, Prophet o modelos causales de uplift.

## Más allá de lo pedido: el sistema en línea

El análisis explica 19 promociones que ya ocurrieron y no impide la número 20. Por eso construí PromoGuard, una compuerta que valida el descuento contra el punto de equilibrio del producto antes de lanzar la promoción, calcula las ventas adicionales necesarias y bloquea las que venden bajo costo. Está publicada con los datos de este extracto: <https://darkgrey-ram-842360.hostingersite.com>

De los \$699,241 de margen destruido, \$96,106 los detiene una regla dura: dos promociones vendieron bajo costo y eso es aritmética, no criterio. Los otros \$603,135 el sistema los marca antes de aprobar, y la decisión sigue siendo del equipo comercial. No eran casos al filo: 12 de esas 17 campañas estaban a menos de la mitad del umbral que necesitaban.

Para VEMIO cambia contra qué presupuesto compite. Un análisis se vende por proyecto; el sistema se vende como suscripción y sale del mismo presupuesto que financia los descuentos, que en estos 6 SKUs fueron \$1,121,460 en 20 meses con un retorno de 38 centavos por dólar. Hubo una decisión cada 4.5 semanas: con 200 SKUs al mismo ritmo son unas 380 al año, y un análisis trimestral no alcanza a tocarlas. El hallazgo tampoco parece exclusivo de este cliente: confundir markup con margen es un error contable, así que puede repetirse en el resto de la cartera. Eso sí, el sistema evita pérdida, no genera ganancia, y la pantalla lo dice con esas palabras.